

**APLICACIONES DE LA ESTRUCTURA TOPOLÓGICA
PARA LA RESOLUCIÓN DE PROBLEMAS EN ENTORNOS
COMPLEJOS DE INGENIERIA.**

AUTOR

Jorge Larry Copa Cruz

Índice

Resumen ejecutivo	4
Introducción	5
1. Antecedentes y estado del arte	6
1.1. Antecedentes teóricos	6
1.2. Frontera del conocimiento	6
1.3. Gap de investigación	6
2. Problema de investigación	7
2.1. Pregunta de investigación	7
3. Objetivos	7
3.1. Objetivo general	7
3.2. Objetivos específicos	7
4. Hipótesis	8
4.1. Hipótesis general	8
4.2. Hipótesis específicas	8
4.3. Operacionalización de las variables	8
5. Delimitación del tema	10
5.1. Delimitación temporal	10
5.2. Delimitación sustantiva	10
6. Justificación	10
6.1. Justificación técnica y científica	11
6.2. Justificación social y aplicada	11
6.3. Justificación académica	11
7. Bases teóricas	12
7.1. Espacio topológico: definición y axiomas	12
7.2. Homeomorfismo e invariantes topológicos	12
7.3. Compacidad, conexidad y separación de Hausdorff	12
8. Desarrollo de la sustentación teórica	13
8.1. Homología persistente y filtraciones	13
8.1.1. Laplacianos topológicos persistentes	13
8.2. Formulación matemática del método SIMP	14
8.2.1. Tabla de notación adoptada	14
8.3. Paradigma de investigación	16
8.4. Métodos de investigación	16
8.5. Tipo de investigación	16
8.6. Técnicas e herramientas	16
8.6.1. Diseño de los casos de simulación	16

8.6.2.	Herramientas computacionales	17
8.6.3.	Criterios de validación y reproducibilidad	17
Bibliografía		18

Resumen ejecutivo

La topología, entendida formalmente como la rama de las matemáticas que estudia las propiedades de los espacios que se preservan bajo transformaciones continuas —los homeomorfismos—, ha experimentado en las últimas tres décadas una transición epistemológica de notable profundidad: ha pasado de ser un campo eminentemente teórico y abstracto a constituirse en un conjunto de herramientas computacionales con aplicación directa y verificable en ingeniería. La ingeniería moderna enfrenta sistemas cuya complejidad supera los métodos basados únicamente en geometría euclidiana y cálculo infinitesimal. Dos frentes de investigación activos proponen salidas complementarias: el *Análisis Topológico de Datos* (TDA), que extrae rasgos invariantes de nubes de puntos ruidosas de alta dimensión, y el método SIMP (*Solid Isotropic Material with Penalization*), que determina la distribución óptima de material en dominios estructurales continuos. Sin embargo, los dos enfoques se han desarrollado de forma aislada, sin un marco integrador que aproveche los invariantes topológicos como regularización dentro del bucle de optimización SIMP es una dirección no explorada.

Establecer una base metodológica formal de las estructuras topológicas y aplicarla sistemáticamente a dos problemas de ingeniería compleja: detección de estructura en datos de alta dimensión mediante TDA; diseño estructural óptimo mediante SIMP, explorando la posibilidad de incorporar descriptores topológicos como métrica de calidad de la topología resultante.

Investigación documental-computacional implementado en Python 3.11+ con las bibliotecas Ripser 0.6, Persim 0.3, PyTorch 2.x, NumPy 1.26 y SciPy 1.12, ejecutadas en Google Colab. Los dos casos de simulación son integralmente reproducibles; no se requiere laboratorio físico.

Se anticipa que la homología persistente proporcionará descriptores estables bajo perturbaciones del 15–20%; y que SIMP convergirá a topologías con al menos 40% de reducción de *compliance* respecto al bloque sólido.

La topología ha dejado de ser patrimonio exclusivo del matemático teórico: sus invariantes constituyen hoy descriptores robustos, computacionalmente accesibles, para elevar la robustez del diseño estructural y del análisis de datos en Ingeniería.

Palabras clave: Topología algebraica computacional, homología persistente, TDA, optimización SIMP, simulación, modelación matemática.

Introducción

A. Antecedentes o estado del Arte del Problema

Cuando los ingenieros del siglo XXI se preguntan “¿cuál es la forma de estos datos?” o “¿cómo distribuir el material para que la estructura sea a la vez rígida y ligera?”, están, sin saberlo, formulando preguntas topológicas. La topología estudia las propiedades de los espacios que permanecen invariantes bajo deformaciones continuas — propiedades que, por construcción, son robustas frente al ruido y a las irregularidades geométricas que caracterizan a los datos y a los diseños reales.

El trabajo seminal de Edelsbrunner, Letscher y Zomorodian (2002) [1] sobre homología persistente demostró que era posible cuantificar la topología de una nube de puntos de forma robusta y computacionalmente eficiente. Desde entonces, el campo del Análisis Topológico de Datos ha confluído con la optimización estructural—donde el método SIMP de Bendsøe (1989) [2] constituye el referente fundacional— y con el aprendizaje profundo informado por física, inaugurado por Raissi, Perdikaris y Karniadakis (2019) [3].

B. Justificación técnica

Ninguno de los enfoques actuales integra los invariantes topológicos como mecanismo de regularización dentro de los bucles de optimización SIMP ni en las funciones de pérdida de las PINNs. La revisión de Su, Liu, Wei et al. (2025) [4] confirma que esta integración sigue siendo un problema abierto. La complejidad computacional de las alternativas para problemas 3D—con matrices de rigidez de orden $\mathcal{O}(10^6)$ — es inviable sin estrategias topológicamente informadas de reducción de dimensión.

C. Descripción del problema

El vacío se enuncia con precisión: no existe un marco matemático que integre la homología persistente del TDA como regularización topológica dentro de los bucles de optimización SIMP. Esta ausencia produce tres consecuencias verificables: los resultados SIMP carecen de garantías sobre $\beta_1(\Omega)$; y el análisis TDA de resultados de ingeniería permanece desacoplado de los procesos que los generan.

D. Estructura del trabajo

Este trabajo se organiza en tres capítulos. El Capítulo I establece el planteamiento completo: antecedentes, problema, objetivos, hipótesis con su operacionalización de variables, delimitación y justificación. El Capítulo II desarrolla la fundamentación teórica formal, desde los axiomas del espacio topológico hasta las formulaciones de TDA, SIMP. El Capítulo III describe el marco metodológico: paradigma, métodos, tipo de investigación y herramientas computacionales para los dos casos de simulación.

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1. Antecedentes y estado del arte

1.1 Antecedentes teóricos

La topología algebraica computacional tiene una fecha de nacimiento identificable: el artículo de Edelsbrunner, Letscher y Zomorodian (2002) [1] en *Discrete & Computational Geometry*, que formalizó la homología persistente como herramienta para cuantificar la topología de datos. Zomorodian y Carlsson (2005) [5] extendieron este trabajo al caso de módulos de persistencia sobre cuerpos arbitrarios. Carlsson (2009) [6] introdujo el TDA como disciplina orientada al análisis de datos.

En optimización estructural, Bendsøe (1989) [2] introdujo el modelo SIMP, y su monografía con Sigmund (2004) [7] sigue siendo la obra de referencia. La revisión comparativa de Sigmund y Maute (2013) [8] establece el mapa de los cuatro grandes métodos: SIMP, conjuntos de nivel, ESO/BESO y componentes morfológicos móviles (MMC).

1.2 Frontera del conocimiento

La revisión de Su, Liu, Wei et al. (2025) [4] en *Artificial Intelligence Review* documenta que los Laplacianos Topológicos Persistentes (PTL) y los Operadores de Dirac Persistentes extienden la homología clásica capturando información geométrica que el barcode pierde. Hensel, Moor y Rieck (2021) [11] sistematizaron más de 120 aplicaciones de TDA en aprendizaje automático. Gowdridge, Dervilis y Worden (2022) [12] demostraron que la homología persistente detecta daño estructural en puentes mediante series temporales de vibración.

En SIMP, Yoo et al. (2023) [13] en el *Journal of Computational Design and Engineering* sistematiza tres décadas de integración de SIMP con aprendizaje automático. Abueidda et al. (2023) [14] demuestran que las PINNs pueden usarse como sustitutos computacionales del análisis de *compliance*. La revisión de Toscano y Karniadakis et al. (2025) [15] revisaron el estado actual de la optimización topológica baja estática no lineal.

1.3 Gap de investigación

A pesar de los avances en TDA, SIMP, ninguno de los marcos actuales integra los invariantes topológicos como regularización transversal dentro de los bucles de optimización y entrenamiento. Esta brecha es el punto de partida de la presente investigación.

2. Problema de investigación

La limitación central no es la ausencia de métodos, sino su **desconexión estructural**: TDA, SIMP se han desarrollado como áreas aisladas, es decir se evita la interferencia entre distintas funciones. Los métodos de optimización topológica producen resultados cuya topología—número de agujeros $\beta_1(\Omega)$, conectividad de la frontera— no está controlada. El análisis TDA ofrece herramientas para cuantificarlas, pero su aplicación a los resultados SIMP ha sido **post hoc**: se analiza la topología de un diseño ya convergido, sin realimentar el proceso.

Esta desconexión tiene consecuencias verificables: los diseños SIMP pueden contener agujeros no intensionales que comprometen la manufacturabilidad; y el TDA de nubes de puntos de alta dimensión (datos de sensores estructurales, ensayos de materiales) permanecen desacoplado de los modelos de optimización que generan esos diseños.

2.1 Pregunta de investigación

¿Cómo aplicar las estructuras topológicas de manera sistemática y verificable para resolver problemas complejos de ingeniería, articulando TDA, SIMP en un marco metodológico común?

3. Objetivos

3.1 Objetivo general

Establecer la base metodológica formal de las estructuras topológicas y aplicarla sistemáticamente a dos dominios de ingeniería compleja—análisis de datos de alta dimensión (TDA) y diseño estructural (SIMP), mediante simulación computacional en Python, demostrando que los invariantes topológicos producen soluciones más robustas que los enfoques exclusivamente euclidianos.

3.2 Objetivos específicos

- OE1.** Revisar y sistematizar los fundamentos teóricos de los espacios topológicos, homeomorfismos, compacidad y homología persistente, articulando las definiciones formales con su implementación computacional.
- OE2.** Calcular y comparar los diagramas de persistencia y los números de Betti β_0, β_1 de nubes de puntos de referencia con diferentes topologías, verificando

estabilidad bajo ruido gaussiano.

- OE3.** Evaluar la eficiencia del método SIMP con factor de penalización $p = 3$ en problemas 2D de elasticidad lineal, cuantificando la reducción de *compliance* y calculando *post hoc* el número de Betti $\beta_1(\Omega_{\text{sólido}})$ de la topología resultante.
- OE4.** Explorar la conexión metodológica entre TDA y SIMP: usar la homología persistente como herramienta de evaluación de la complejidad topológica de los diseños SIMP.

4. Hipótesis

4.1 Hipótesis general

La aplicación sistemática de estructuras topológicas—mediante TDA, SIMP,—proporciona soluciones **más robustas, eficientes y globalmente consistentes** a los problemas planteados en entornos complejos de ingeniería, en comparación con los métodos basados exclusivamente en geometría euclidiana y análisis infinitesimal local.

4.2 Hipótesis específicas

H.E.1 — TDA

La homología persistente, computada sobre nubes de puntos $X \subset \mathbb{R}^d$ ($d \leq 100$) con Ripser 0.6, proporciona números de Betti β_0 y β_1 que permanecen estables bajo perturbaciones del 15–20 % en los datos de entrada, superando a los descriptores euclidianos en tareas de clasificación y detección de anomalías.

H.E.2 — SIMP

El método SIMP con $p = 3$ y fracción de volumen $f_V = 0.5$ converge a una distribución de material que reduce la *compliance* global en al menos un 40 % respecto al bloque sólido de referencia, generando una topología con $\beta_1(\Omega_{\text{sólido}}) \leq 2$ verificable computacionalmente.

4.3 Operacionalización de las variables

La operacionalización traduce cada hipótesis en variables medibles. En matemática computacional las variables son parámetros, operadores o indicadores de rendimiento; no entidades cualitativas. La Tabla 1 organiza las variables de los cuatro ejes de investigación.

Cuadro 1: Operacionalización de las variables de investigación.

Variable	Tipo	Definición operacional / Indicador	Instrumento
Parámetro ε de la filtración $VR(X, \varepsilon)$	Independiente	Umbral de conectividad que controla la construcción del complejo de Vietoris-Rips. Rango: $[0, \text{diam}(X)]$.	Ripser 0.6 / <code>numpy.linspace</code>
Números de Betti β_0, β_1	Dependiente	Componentes conexas (β_0) y ciclos independientes (β_1) del complejo a cada escala ε . Métrica: variación porcentual bajo ruido gaussiano $\sigma_n = 0.10 \text{ diam}(X)$.	Persim 0.3, diagrama de persistencia
Factor de penalización p (SIMP)	Independiente	Exponente de la ley de potencias $E_e(\rho_e) = \rho_e^p E_0$. Valores de prueba: $p \in \{1, 2, 3, 4\}$.	Script FEM en Python
<i>Compliance</i> $c(\boldsymbol{\rho})$	Dependiente	Trabajo de deformación total $c = \mathbf{U}^T \mathbf{K}(\boldsymbol{\rho}) \mathbf{U}$. Reducción relativa (%) respecto al bloque sólido.	<code>scipy.sparse.linalg</code>
Dimensionalidad d de datos (TDA)	Interviniente	Número de atributos por muestra. Rango acotado: $d \leq 100$, lo que garantiza factibilidad de $VR(X, \varepsilon)$.	Conjuntos públicos (UCI, Zenodo)
Resolución de malla N_e (SIMP)	Interviniente	Número de elementos finitos. $N_e \in \{1\,600, 6\,400, 14\,400\}$ (mallas 40×40 , 80×80 , 120×120).	Script Python propio

Nota: Las variables intervinientes no se manipulan durante el experimento; se controlan fijándolas en los valores indicados para garantizar la reproducibilidad de los resultados.

5. Delimitación del tema

5.1 Delimitación temporal

La revisión bibliográfica cubre literatura publicada entre 2002 y julio de 2026 en revistas indexadas JCR/Scopus (Web of Science, Scopus, IEEE Xplore, arXiv), priorizando artículos Q1/Q2 de los últimos cinco años. El período de implementación computacional corresponde al ciclo académico 2025–2026. Las versiones de software son: Python 3.11+, Ripser 0.6, Persim 0.3, PyTorch 2.x, NumPy 1.26, SciPy 1.12, Matplotlib 3.8 y scikit-learn 1.4.

5.2 Delimitación sustantiva

Cuadro 2: Fronteras sustantivas de la investigación.

Ámbito	Dentro del alcance	Fuera del alcance
Campo matemático	Topología algebraica computacional (homología persistente), análisis numérico (FEM, RK4), aprendizaje profundo científico (PINNs, Neural ODEs)	Topología diferencial, K -teoría, cohomología de de Rham, teoría de nudos avanzada
TDA	Complejos de Vietoris-Rips en $\mathbb{R}^d$, $d \leq 100$; homología persistente unidimensional en parámetro	Homología persistente multi-parámetro; módulos de persistencia en ≥ 2 parámetros
SIMP	Problemas 2D de elasticidad lineal; dominio rectangular discretizado con FEM Q4	Optimización 3D, restricciones de manufactura aditiva, multi-física
Software	Python en Google Colab (GPU T4/A100); bibliotecas de código abierto con licencia MIT/BSD	MATLAB, ANSYS, software propietario, hardware de laboratorio

6. Justificación

6.1 Justificación técnica y científica

Los métodos numéricos clásicos resuelven bien problemas locales y lineales, pero exhiben limitaciones sistemáticas ante dos escenarios frecuentes en ingeniería moderna: datos de alta dimensión con estructura no euclidiana, diseños estructurales donde la topología de la solución importa tanto como su rigidez. La justificación técnica es directa: por el Teorema de Estabilidad de Cohen-Steiner, Edelsbrunner y Harer (2007) [16], los invariantes topológicos son robustos frente a perturbaciones continuas por construcción, lo que los hace superiores a los descriptores euclidianos en entornos ruidosos.

La brecha identificada—la ausencia de un marco TDA-SIMP integrado— es suficientemente bien definida, computacionalmente abordable y de alto impacto como para constituir el núcleo de una investigación de maestría original. La revisión de Xu, Zhang et al. (2025) [17] documenta reducciones del costo computacional en espacios de alta dimensión, lo que cuantifica el potencial de impacto.

6.2 Justificación social y aplicada

Bolivia y América Latina enfrentan necesidades concretas en los dos dominios de aplicación elegidos. En **ingeniería de datos**, el análisis topológico ofrece herramientas robustas para datos genómicos, agrícolas e hidrológicos que son, por naturaleza, ruidosos y de alta dimensión. En **ingeniería civil**, la optimización SIMP puede reducir el uso de material entre el 30 % y el 50 %, con impacto directo en el costo de infraestructura pública.

6.3 Justificación académica

Este trabajo contribuye a las líneas de investigación **Mod.7. Geometría y Topología**, **Mod.8. Matemática Computacional** y **Mod.9. Modelación Matemática** de la Maestría en Matemática de la UAGRM-FII. Genera tres tipos de aporte institucional: (i) material docente formal—definiciones, teoremas y código Python comentado— que puede incorporarse a cursos de posgrado; (ii) un *framework* computacional en Google Colab reproducible sin hardware especializado; y (iii) antecedentes bibliográficos actualizados (2020–2026) para investigaciones futuras en la institución.

CAPÍTULO II: FUNDAMENTACIÓN TEÓRICA

7. Bases teóricas

7.1 Espacio topológico: definición y axiomas

Definición 2.1 (Espacio Topológico). Sea E un conjunto no vacío. Una **topología** sobre E es una familia $\mathcal{T} \subseteq \mathcal{P}(E)$ que satisface:

- (T1) Estabilidad bajo uniones arbitrarias: si $\{G_\alpha\}_{\alpha \in I} \subseteq \mathcal{T}$, entonces $\bigcup_{\alpha \in I} G_\alpha \in \mathcal{T}$.
- (T2) Estabilidad bajo intersecciones finitas: si $G_1, G_2 \in \mathcal{T}$, entonces $G_1 \cap G_2 \in \mathcal{T}$.
- (T3) Elementos triviales: $\emptyset \in \mathcal{T}$ y $E \in \mathcal{T}$.

El par $(E, \mathcal{T})$ es el **espacio topológico**. Los elementos de $\mathcal{T}$ se llaman **conjuntos abiertos**.

La topología usual de $\mathbb{R}$ está inducida por la métrica euclidiana $d(x, y) = |x - y|$: un conjunto $G \subseteq \mathbb{R}$ es abierto si y solo si para cada $x_0 \in G$ existe $\varepsilon > 0$ tal que $(x_0 - \varepsilon, x_0 + \varepsilon) \subseteq G$. Este ejemplo conecta la abstracción topológica con el cálculo numérico.

7.2 Homeomorfismo e invariantes topológicos

Definición 2.2 (Homeomorfismo). Una función $f : E \rightarrow F$ entre espacios topológicos es un **homeomorfismo** si es biyectiva, continua y de inversa continua. Si tal f existe se escribe $E \cong F$. Un **invariante topológico** es una propiedad que toma el mismo valor en espacios homeomorfos.

Los **números de Betti** $\beta_k = \dim H_k$ son los invariantes más directamente interpretables: β_0 cuenta componentes conexas, β_1 ciclos 1-dimensionales (agujeros) y β_2 cavidades 2-dimensionales. Son los descriptores que el TDA cuantifica a lo largo de una filtración.

7.3 Compacidad, conexidad y separación de Hausdorff

Un espacio $(E, \mathcal{T})$ es **compacto** si toda cubierta abierta admite una subcubierta finita; en $\mathbb{R}^n$, por el Teorema de Heine-Borel, esto equivale a ser cerrado y acotado. La compacidad garantiza la existencia de soluciones óptimas en SIMP. Un espacio es **conexo** si no puede expresarse como unión de dos abiertos disjuntos no vacíos; en TDA, la conexidad se cuantifica por β_0 . La condición de **Hausdorff** (T_2)—para cualesquiera $a \neq b$ existen entornos disjuntos—garantiza la unicidad de límites de sucesiones, condición necesaria para el análisis numérico riguroso:

$$d(a, b) = r \implies B\left(a, \frac{r}{2}\right) \cap B\left(b, \frac{r}{2}\right) = \emptyset.$$

8. Desarrollo de la sustentación teórica

Bloque A Análisis Topológico de Datos (TDA)

8.1 Homología persistente y filtraciones

El TDA, inaugurado por Edelsbrunner et al. (2002) [1] y algebraicamente fundamentado por Zomorodian y Carlsson (2005) [5], responde a la pregunta: dada una nube de puntos $X = \{x_1, \dots, x_n\} \subset \mathbb{R}^d$, ¿qué rasgos topológicos—agujeros, cavidades, componentes—son estadísticamente significativos? La herramienta es la **filtración de Vietoris-Rips**:

$$\text{VR}(X, \varepsilon) = \left\{ \sigma \subseteq X : d(x_i, x_j) \leq \varepsilon \quad \forall x_i, x_j \in \sigma \right\}, \quad (1)$$

que forma una familia anidada $\{\text{VR}(X, \varepsilon)\}_{\varepsilon \geq 0}$ cuyos grupos de homología H_k evolucionan con ε . Cada rasgo topológico k -dimensional nace en $\varepsilon = b_i$ y muere en $\varepsilon = d_i$, formando el **diagrama de persistencia**

$$\text{Dgm}_k(X) = \{(b_i, d_i)\}_i \subset \mathbb{R}^2.$$

Teorema 2.1 (Estabilidad, Cohen-Steiner, Edelsbrunner y Harer, 2007 [16]).

Sean $f, g : \mathcal{K} \rightarrow \mathbb{R}$ funciones de Morse sobre un complejo simplicial $\mathcal{K}$. Entonces la *distancia botella* entre sus diagramas de persistencia satisface

$$d_\infty(\text{Dgm}(f), \text{Dgm}(g)) \leq \|f - g\|_\infty, \quad (2)$$

donde la distancia botella se define como $d_\infty(A, B) = \inf_{\phi: A \rightarrow B} \sup_{p \in A} \|p - \phi(p)\|_\infty$, con el ínfimo sobre todas las biyecciones.

El Teorema (2) garantiza que pequeñas perturbaciones en los datos producen pequeños cambios en los diagramas de persistencia, dotando al TDA de robustez intrínseca frente al ruido de medición.

8.1.1 Laplacianos topológicos persistentes

Wang y Wei (2020) [18] introdujeron los Laplacianos Combinatorios Persistentes:

$$\Delta_k = \partial_k^* \partial_k + \partial_{k+1} \partial_{k+1}^*, \quad (3)$$

cuyo espectro armónico recupera la homología y cuyo espectro no armónico aporta información geométrica que el barcode pierde. La revisión de Su et al. (2025) [4] documenta aplicaciones a predicción de variantes virales (SARS-CoV-2) y ligación proteínaligando, confirmando la superioridad del enfoque espectral en datos biológicos de alta complejidad.

Bloque B Optimización Topológica SIMP

8.2 Formulación matemática del método SIMP

El método SIMP, introducido por Bendsøe (1989) [2] y sistematizado en Bendsøe y Sigmund (2004) [7], modela el módulo de Young de cada elemento finito mediante la ley de potencias

$$E_e(\rho_e) = \rho_e^p E_0, \quad \rho_e \in (0, 1], \quad p \geq 3, \quad (4)$$

donde E_0 es el módulo del material sólido y p es el factor de penalización (en la práctica $p = 3$ incentiva soluciones binarias). El problema de optimización es:

$$\begin{aligned} \min_{\boldsymbol{\rho}} c(\boldsymbol{\rho}) &= \mathbf{U}^\top \mathbf{K}(\boldsymbol{\rho}) \mathbf{U} = \sum_{e=1}^{N_e} \rho_e^p \mathbf{u}_e^\top \mathbf{K}_0 \mathbf{u}_e, \\ \text{s.a. } \mathbf{K}(\boldsymbol{\rho}) \mathbf{U} &= \mathbf{F}, \\ \frac{V(\boldsymbol{\rho})}{V_0} &= \frac{\sum_{e=1}^{N_e} \rho_e v_e}{\sum_{e=1}^{N_e} v_e} = f_V, \\ 0 < \rho_{\min} &\leq \rho_e \leq 1, \quad e = 1, \dots, N_e, \end{aligned} \quad (5)$$

donde $\mathbf{K}(\boldsymbol{\rho})$ es la matriz de rigidez global, $\mathbf{U}$ el vector de desplazamientos, $\mathbf{F}$ las fuerzas externas, v_e el volumen del elemento e , $f_V \in (0, 1)$ la fracción de volumen objetivo y $\rho_{\min} > 0$ un umbral de regularización. Las sensibilidades, obtenidas por el método adjunto, son:

$$\frac{\partial c}{\partial \rho_e} = -p \rho_e^{p-1} \mathbf{u}_e^\top \mathbf{K}_0 \mathbf{u}_e \leq 0, \quad (6)$$

lo que garantiza que incrementar la densidad de cualquier elemento nunca aumenta la *compliance*. La revisión de Yoo et al. (2023) [13] documenta que la integración con redes neuronales convolucionales ha acelerado SIMP hasta lograr predicciones en milisegundos para casos 2D con índice IoU > 0.95 . El vacío permanente es que ningún método actual controla directamente $\beta_1(\Omega_{\text{sólido}})$ durante la optimización.

8.2.1 Tabla de notación adoptada

Para evitar ambigüedades en el resto del trabajo, la Tabla 3 fija la simbología matemática empleada.

Cuadro 3: Notación matemática adoptada en la investigación.

Símbolo	Descripción	Dominio
$X = \{x_1, \dots, x_n\} \subset \mathbb{R}^d$	Nube de puntos de entrada	TDA
$\text{VR}(X, \varepsilon)$	Complejo de Vietoris-Rips a escala ε	TDA
$\text{Dgm}_k(X)$	Diagrama de persistencia de dimensión k	TDA
$\beta_k = \dim H_k$	Número de Betti de dimensión k	TDA / General
$d_\infty(A, B)$	Distancia botella entre diagramas	TDA
$\rho_e \in (0, 1]$	Densidad de diseño del elemento e	SIMP
$E_e = \rho_e^p E_0$	Módulo de Young penalizado	SIMP
$c(\boldsymbol{\rho}) = \mathbf{U}^\top \mathbf{K} \mathbf{U}$	Función <i>compliance</i>	SIMP

CAPÍTULO III. Marco metodológico

8.3 Paradigma de investigación

La investigación se inscribe en el paradigma **positivista-cuantitativo**. Se parte de proposiciones teóricas precisas (hipótesis medibles), se diseñan experimentos computacionales reproducibles, se recolectan datos numéricos y se contrastan las hipótesis mediante indicadores estadísticos. La verdad de una proposición se juzga por su correspondencia con los resultados de la simulación, no por autoridad bibliográfica.

8.4 Métodos de investigación

Se emplean dos métodos en combinación. El **método deductivo y modelación experimental**, opera de la teoría (axiomas topológicos, teoremas de estabilidad, formulación SIMP) hacia las predicciones verificables de las hipótesis específicas. El **método comparativo** contrasta el rendimiento de los métodos topológicos (TDA, SIMP) frente a sus análogos no topológicos de referencia (descriptores euclidianos), cuantificando la mejora relativa mediante las métricas de la Tabla 1.

8.5 Tipo de investigación

La investigación es de tipo **aplicada, descriptivo-explicativa y de carácter documental computacional**. Es *aplicada* porque utiliza teoría matemática establecida para resolver problemas concretos de ingeniería. Es *descriptivo-explicativa* porque no solo describe los fenómenos (estructura topológica de los datos, topología del diseño óptimo) sino que explica causalmente su comportamiento mediante los invariantes topológicos. Es *documental-computacional* porque combina la revisión sistemática de la literatura con la simulación numérica como fuente primaria de evidencia, sin requerir laboratorio físico.

8.6 Técnicas e herramientas

8.6.1 Diseño de los casos de simulación

Dos casos articulan las dos hipótesis específicas:

- **Caso 1 — Ingeniería de Datos (TDA):** computación de homología persistente sobre conjuntos de datos de referencia (esferas, toros, nubes ruidosas) con Ripser 0.6. Prueba de estabilidad: perturbación gaussiana escalada al 10 %, 15 % y 20 % del diámetro. Comparación de β_0/β_1 vs. descriptores PCA y k -medias.
- **Caso 2 — Ingeniería Estructural (SIMP):** viga en voladizo 2D, 60×30 elementos Q4, carga puntual en extremo libre, $f_V = 0.5$, $p = 3$. Métrica primaria: *compliance* relativa. Métrica topológica: $\beta_1(\Omega_{\text{sólido}})$ calculado con Ripser sobre la malla resultante.

8.6.2 Herramientas computacionales

Cuadro 4: Herramientas computacionales y su caso de uso.

Herramienta	Versión	Caso de uso
Python	3.11+	Lenguaje base de todos los casos
Ripser	0.6.x	Homología persistente (Casos 1)
Persim	0.3.x	Visualización de diagramas, distancia de Wasserstein
NumPy / SciPy	1.26/1.12	Álgebra lineal, integración ODE, optimización
PyTorch	2.x	Diferenciación automática.
Matplotlib	3.8.x	Visualización científica (para los dos casos)
scikit-learn	1.4.x	Validación, métricas, reducción de dimensión
Google Colab	GPU T4/A100	Entorno de ejecución sin hardware especializado

8.6.3 Criterios de validación y reproducibilidad

- **Reproducibilidad:** todo el código se versionará en un repositorio público (GitHub) con semilla aleatoria fija (`seed = 42`) en todos los experimentos estocásticos.
- **Convergencia SIMP:** criterio de parada dual: cambio relativo en $c(\boldsymbol{\rho})$ menor que 10^{-4} y cambio máximo en densidades menor que 10^{-3} entre iteraciones consecutivas.
- **Comparación estadística:** los resultados de estabilidad TDA se reportarán como media $\pm$ desviación estándar sobre 100 realizaciones de ruido gaussiano.
- **Documentación:** cada caso de simulación se entregará como un Notebook Jupyter (`.ipynb`) con celdas comentadas, figuras embebidas y tablas de resultados exportadas a CSV.

Bibliografía

Referencias ordenadas por primera aparición en el texto. Todos los artículos de revista están indexados en JCR (Web of Science) o Scopus.

Referencias

- [1] Edelsbrunner, H., Letscher, D., & Zomorodian, A. (2002). Topological persistence and simplification. *Discrete & Computational Geometry*, **28**(4), 511–533. <https://doi.org/10.1007/s00454-002-2885-2>
- [2] Bendsøe, M. P. (1989). Optimal shape design as a material distribution problem. *Structural Optimization*, **1**(4), 193–202. <https://doi.org/10.1007/BF01650949>
- [3] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, **378**, 686–707. <https://doi.org/10.1016/j.jcp.2018.10.045>
- [4] Su, Z., Liu, X., Bou Hamdan, L., Maroulas, V., Wu, J., Carlsson, G., & Wei, G.-W. (2025). Topological data analysis and topological deep learning beyond persistent homology: A review. *Artificial Intelligence Review*, **58**. <https://doi.org/10.1007/s10462-025-11462-w>
- [5] Zomorodian, A., & Carlsson, G. (2005). Computing persistent homology. *Discrete & Computational Geometry*, **33**(2), 249–274. <https://doi.org/10.1007/s00454-004-1146-y>
- [6] Carlsson, G. (2009). Topology and data. *Bulletin of the American Mathematical Society*, **46**(2), 255–308. <https://doi.org/10.1090/S0273-0979-09-01249-X>
- [7] Bendsøe, M. P., & Sigmund, O. (2004). *Topology Optimization: Theory, Methods, and Applications* (2nd ed.). Springer-Verlag. ISBN 978-3-662-05086-6.
- [8] Sigmund, O., & Maute, K. (2013). Topology optimization approaches: A comparative review. *Structural and Multidisciplinary Optimization*, **48**(6), 1031–1055. <https://doi.org/10.1007/s00158-013-0978-6>
- [9] Lorenz, E. N. (1963). Deterministic nonperiodic flow. *Journal of the Atmospheric Sciences*, **20**(2), 130–141. [https://doi.org/10.1175/1520-0469\(1963\)020<0130:DNF>2.0.CO;2](https://doi.org/10.1175/1520-0469(1963)020<0130:DNF>2.0.CO;2)
- [10] Tucker, W. (2002). A rigorous ODE solver and Smale’s 14th problem. *Foundations of Computational Mathematics*, **2**(1), 53–117. <https://doi.org/10.1007/s002080010018>
- [11] Hensel, F., Moor, M., & Rieck, B. (2021). A survey of topological machine learning methods. *Frontiers in Artificial Intelligence*, **4**, 681108. <https://doi.org/10.3389/frai.2021.681108>

- [12] Gowdrige, T., Dervilis, N., & Worden, K. (2022). On topological data analysis for structural dynamics: An introduction to persistent homology. *ASME Open Journal of Engineering*, **1**, 011038. <https://doi.org/10.1115/1.4055184>
- [13] Yoo, S., Lee, S., Kim, S., Hwang, K. H., Park, J. H., & Kang, N. (2023). Topology optimization via machine learning and deep learning: A review. *Journal of Computational Design and Engineering*, **10**(4), 1736–1766. <https://doi.org/10.1093/jcde/qwad072>
- [14] Abueidda, D. W., Koric, S., Sobh, N. A., & Sehitoglu, H. (2023). Topology optimization with physics-informed neural networks. *Computer Methods in Applied Mechanics and Engineering*, **415**, 116276. <https://doi.org/10.1016/j.cma.2023.116276>
- [15] Toscano, J. D., Oommen, V., Varghese, A. J., Zou, Z., Ahmadi Daryakenari, N., Wu, C., & Karniadakis, G. E. (2025). From PINNs to PIKANs: Recent advances in physics-informed machine learning. *Machine Learning for Computational Science and Engineering*, **1**(1). <https://doi.org/10.1007/s44379-025-00015-1>
- [16] Cohen-Steiner, D., Edelsbrunner, H., & Harer, J. (2007). Stability of persistence diagrams. *Discrete & Computational Geometry*, **37**(1), 103–120. <https://doi.org/10.1007/s00454-006-1276-5>
- [17] Xu, Z., Zhang, Y., & Li, M. (2025). Physics-informed neural networks: A review of methodological evolution, theoretical foundations, and interdisciplinary frontiers toward next-generation scientific computing. *Applied Sciences*, **15**(14), 8092. <https://doi.org/10.3390/app15148092>
- [18] Wang, R., & Wei, G.-W. (2020). Persistent spectral graph. *International Journal for Numerical Methods in Biomedical Engineering*, **36**(9), e3376. <https://doi.org/10.1002/cnm.3376>
- [19] Bendsøe, M. P., & Kikuchi, N. (1988). Generating optimal topologies in structural design using a homogenization method. *Computer Methods in Applied Mechanics and Engineering*, **71**(2), 197–224. [https://doi.org/10.1016/0045-7825\(88\)90086-2](https://doi.org/10.1016/0045-7825(88)90086-2)
- [20] Chazal, F., & Michel, B. (2021). An introduction to topological data analysis: Fundamental and practical aspects for data scientists. *Frontiers in Artificial Intelligence*, **4**, 667963. <https://doi.org/10.3389/frai.2021.667963>
- [21] Brunton, S. L., Proctor, J. L., & Kutz, J. N. (2016). Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *PNAS*, **113**(15), 3932–3937. <https://doi.org/10.1073/pnas.1517384113>
- [22] Ameneyro, B., Maroulas, V., & Siopsis, G. (2024). Quantum persistent homology. *Journal of Applied and Computational Topology*, **8**, 1961–1983. <https://doi.org/10.1007/s41468-023-00115-y>
- [23] Svanberg, K. (1987). The method of moving asymptotes: A new method for structural optimization. *International Journal for Numerical Methods in Engineering*, **24**(2), 359–373. <https://doi.org/10.1002/nme.1620240207>

- [24] Xu, B., Jiang, H., & Chen, L. (2024). Topology optimization: A review for structural designs under statics problems. *Materials*, **17**(23), 5970. <https://doi.org/10.3390/ma17235970>
- [25] Farea, A., Yli-Harja, O., & Emmert-Streib, F. (2024). Understanding physics-informed neural networks: Techniques, applications, trends, and challenges. *Artificial Intelligence Review*, **57**(12). <https://doi.org/10.1007/s10462-024-10939-4>